

LAPORAN TUGAS BESAR DEEP LEARNING

Perbandingan Machine Learning dan Deep Learning untuk Deteksi, Pemetaan Poligon, dan Perencanaan Respons Tumpahan Minyak pada Citra Sentinel-1 SAR di Browser

(Kasus 38: Marine Oil Spill Detection and Mapping via Satellite SAR)



Disusun oleh:

Kelompok 1 — CAYMAN

Ade Rizky Darmawan (Ketua)	NPM : 23083010080
Arkananta Daniswara Handoyo	NPM : 23083010059
Muhammad Arsyad Alzam	NPM : 23083010082
Choirul Amin	NPM : 22083010050
Hana Titania Sastrian	NPM : 23083010056
Zaydan Arief Athallah	NPM : 23083010063

Dosen Pengampu:

Dr. I Gede Susrama Mas Diyasa, ST., MT.

Dosen Praktisi:

Kahpi Baiquni Arifani, S.Kom., M.Kom.

**PROGRAM STUDI SAINS DATA
FAKULTAS ILMU KOMPUTER
UPN "VETERAN" JAWA TIMUR
2026**

Perbandingan Machine Learning dan Deep Learning untuk Deteksi, Pemetaan Poligon, dan Perencanaan Respons Tumpahan Minyak pada Citra Sentinel-1 SAR di Browser

Kelompok 1 — CAYMAN · Kasus 38: *Marine Oil Spill Detection and Mapping via Satellite SAR*

Kode & dokumentasi: github.com/aderizkydarmawan/cayman-oil-spill-sar · Aplikasi web: [cayman-kelompok1.vercel.app](https://kelompok1.vercel.app)

Abstrak — Tumpahan minyak dari fasilitas migas lepas pantai, pipa bawah laut, dan kapal tanker harus dipetakan secepat mungkin agar respons HSSE tepat sasaran. Penelitian ini membandingkan dua model *machine learning* (Random Forest dan LightGBM dengan 13 fitur tekstur buatan) dan dua model *deep learning* (U-Net Lite yang dilatih dari nol dan DeepLabV3+ MobileNetV2 pralatih) untuk segmentasi tumpahan minyak pada citra Sentinel-1 SAR dataset SOS (2.850 latih, 504 validasi, 839 uji). Semua model memakai split, aturan threshold (dipilih pada data validasi), dan metrik yang sama. Pada data uji, DeepLabV3+ mencapai Dice 0,867 dan IoU 0,765, disusul U-Net Lite (0,855), LightGBM (0,806), dan Random Forest (0,804), seluruhnya di atas baseline *dark-spot* (0,726). Model DL unggul 5–6 poin Dice terutama karena precision yang lebih tinggi, sedangkan model ML sangat kecil (0,24–1,8 MB). Kelima model diekspor ke ONNX (DL dikuantisasi INT8 tanpa penurunan Dice yang berarti) dan dijalankan di browser. Aplikasi web juga mengubah mask menjadi poligon per slick, mensimulasikan arah dan laju penyebaran (drift 3% angin + arus, penyebaran Fay dan difusi Okubo), memperkirakan panjang *oil boom*, serta menghitung efisiensi biaya dan penurunan risiko HSSE akibat berkurangnya patroli lapangan.

Kata kunci: *oil spill, SAR, Sentinel-1, segmentasi semantik, random forest, LightGBM, U-Net, DeepLabV3+, edge AI, oil boom, HSSE.*

1. Pendahuluan

Tumpahan minyak adalah salah satu ancaman terbesar bagi ekosistem laut, dan sebagian besar terkait aktivitas industri migas lepas pantai: semburan dari rig pengeboran, kecelakaan tanker, hingga buangan rutin kapal [6]. Pada pilar **HSSE** (*Health, Safety, Security and Environment*), tim respons membutuhkan lokasi, luas, dan arah gerak tumpahan secepat mungkin untuk menentukan penempatan *oil boom*, *skimmer*, dan kapal penanggulangan [1]. Pengecekan manual melalui patroli udara atau laut mahal dan memaparkan personel pada uap hidrokarbon serta risiko kecelakaan.

Radar apertur sintesis (SAR) menjadi sensor utama pemantauan tumpahan minyak karena bekerja siang–malam dan menembus awan. Lapisan minyak meredam gelombang kapiler sehingga tampak sebagai area gelap pada citra SAR [1]. Liao dkk. menemukan lebih dari 80% kejadian tumpahan di Teluk Jiaozhou terjadi pada malam hari [8]. Tantangan utamanya adalah fenomena *look-alike* (angin lemah, lapisan biogenik) yang juga tampak gelap [2], [4], [7]. Tabel 1 merangkum penelitian rujukan; angka antarpemeriksaan umumnya **tidak dapat dibandingkan langsung** karena dataset dan protokolnya berbeda, kecuali Zhu dkk. [3] yang memperkenalkan dataset SOS yang juga kami gunakan.

Kontribusi proyek ini: (1) *pipeline* yang diaudit, termasuk pemeriksaan kebocoran antar split; (2) perbandingan adil model ML dan DL pada protokol yang sama, termasuk uji lintas sensor; (3) aplikasi web dengan inferensi di sisi klien untuk kelima model, poligon per slick, dan GeoJSON; serta (4) simulasi arah dan laju penyebaran, estimasi kebutuhan *oil boom*, dan analisis biaya serta risiko HSSE.

Tabel 1. Ringkasan penelitian rujukan (state of the art).


Rujukan	Data	Metode	Hasil utama (sesuai paper)
Zhu dkk., 2022 [3]	SOS: ALOS PALSAR & Sentinel-1A	CBD-Net (multiskala, scSE, supervisi tepi)	Sentinel-1: mIoU 83,42%, F1 87,87%
Shaban dkk., 2021 [5]	SAR, dataset tidak seimbang	CNN 23 lapis + U-Net 5 tahap	Dice 80%, precision 84%
Hasimoto-Beltran dkk., 2023 [6]	16 citra ENVISAT-ASAR	M-DNN multi-kanal (U-Net + ResNet)	F1 hingga 98,24% (dataset sendiri)
Li dkk., 2023 [7]	Sentinel-1	Algoritma DL <i>self-evolving</i>	F1 0,8423 → 0,8896 (21 siklus)
Liao dkk., 2023 [8]	35 citra Sentinel-1 PolSAR	DeepLabv3+ + fitur polarimetrik	OA 0,9812; MIoU 0,9599
Das dkk., 2024 [9]	SAR, 5 kelas	U-Net multi-backbone (EfficientNet-B3)	mIoU 76,53%; IoU minyak 62,08%
Petalas dkk., 2025 [10]	Sentinel-1, Laut Aegea	U-Net operasional + model dispersi	IoU kelas minyak 0,30

2. Metodologi

2.1 Dataset, audit, dan split

Dataset *Deep-SAR Oil Spill* (SOS) [3] diunduh dari Kaggle melalui kagglehub [13] (lisensi CC BY 4.0). SOS berisi 8.070 pasangan citra–mask PNG 256×256 dari ALOS PALSAR (Teluk Meksiko; 3.101 latih / 776 uji) dan Sentinel-1A VV (Teluk Persia; 3.354 latih / 839 uji). Audit menemukan: semua pasangan cocok tanpa NaN/Inf; ketiga kanal RGB identik sehingga model memakai 1 kanal; label latih memiliki 2,2–2,5% piksel bernilai antara sehingga dibinerkan dengan aturan ≥ 128 ; tidak ada duplikat eksak, dan pemeriksaan *near-duplicate* dengan *average hash* terhadap 8 rotasi/flip hanya menemukan 9 citra uji yang mirip citra latih (dampaknya diuji di Subbab 3.1).

Eksperimen memakai **Sentinel-1** (sampel terbanyak, label ambigu lebih sedikit, data terbuka). Data latih dibagi 2.850 latih dan 504 validasi (*seed* 42) dengan mengelompokkan komponen *near-duplicate* agar tidak terpisah; set uji 839 citra hanya dipakai untuk evaluasi akhir. Citra dinormalisasi $z\text{-score } x' = (x/255 - 0,3834)/0,2020$ dengan statistik dari data latih. Augmentasi (8 rotasi/flip identik untuk citra dan mask, jitter kecerahan $\pm 10\%$) hanya pada data latih.

**Gambar 1.** Alur sistem, dari data hingga aplikasi web.

2.2 Model Machine Learning dan Deep Learning

- **Random Forest** [15] dan **LightGBM** [16] mengklasifikasi setiap piksel dari 13 fitur buatan tangan: intensitas; rata-rata lokal 5/11/21/41 piksel; simpangan baku lokal 5/11/21 (tekstur); gradien Sobel (tepi); kontras rata-rata 5 vs 41; selisih terhadap rata-rata citra; serta minimum dan maksimum lokal 11 piksel. Fitur ditulis sebagai modul PyTorch agar identik di notebook dan browser. Model dilatih pada 300 piksel acak per citra latih (855.000 baris) dengan ukuran dibatasi agar ringan di web: RF 20 pohon kedalaman 12, LightGBM 100 pohon 31 daun.

- **U-Net Lite** adalah U-Net [11] 4 level dengan kanal 16–256 (1,94 juta parameter) yang dilatih dari nol. **DeepLabV3+** [17] memakai *encoder* MobileNetV2 [18] pralatih ImageNet (4,38 juta parameter; bobot kanal pertama dijumlahkan menjadi 1 kanal). Keduanya dilatih dengan resep yang sama: loss $0,5 \cdot \text{BCE} + 0,5 \cdot \text{Dice}$, AdamW (lr 10^{-3} , *weight decay* 10^{-4}), jadwal *cosine* 40 epoch, *batch* 16, dan *mixed precision* pada GPU Tesla T4 (Google Colab). Checkpoint terbaik dipilih dari Dice validasi.

Threshold setiap model dipilih melalui *sweep* 0,20–0,80 pada data **validasi**. Metrik utama adalah Dice (F1 piksel), IoU, precision, recall, dan PR-AUC dengan agregasi global (TP/FP/FN/TN dijumlahkan dari semua piksel uji). Baseline *dark-spot thresholding* (blur 7×7 , intensitas < 70 ; ambang dipilih pada data latih) disertakan, dan generalisasi lintas sensor diuji pada 776 citra PALSAR.

2.3 Edge AI, poligon, dan simulasi respons

Model DL diekspor ke ONNX lalu dikuantisasi INT8 statis (QDQ per-kanal) [12] dengan kalibrasi 200 citra latih; varian web adalah varian terkecil yang penurunan Dice validasinya $\leq 0,005$. Model ML diekspor sebagai satu graf ONNX (graf fitur + *ensemble* pohon). Aplikasi web statis di Vercel menjalankan kelima model dengan onnxruntime-web [14] (WebAssembly multi-thread), sehingga citra pengguna tidak pernah dikirim ke server. Setelah inferensi, mask dipecah menjadi komponen terhubung, batas luar tiap slick ditelusuri lalu disederhanakan dengan Douglas–Peucker, sehingga diperoleh luas, keliling, dan poligon GeoJSON per slick.

Simulasi skenario (*what-if*) memproyeksikan poligon ke depan. **Drift**: kecepatan slick = 3% kecepatan angin + 100% arus permukaan, aturan praktis yang juga dipakai model trajektori NOAA GNOME [19]. **Penyebaran**: persamaan Fay [20] rezim gravitasi-viskos $A \propto \sqrt[3]{(\Delta \cdot g \cdot V^2 / \sqrt{v})} \cdot \sqrt{t}$, dengan volume $V = \text{luas} \times \text{ketebalan}$ menurut kode penampakan Bonn Agreement [21], ditambah difusi turbulen $\Delta A = 8\pi K \cdot t$ dengan K dari hukum skala Okubo [22] ($K = 0,0103 \times L$ pangkat 1,15, dalam cm^2/s , $L = \text{diameter slick dalam cm}$). **Kebutuhan oil boom** = $1,3 \times \text{keliling convex hull slick}$ saat tim tiba, dengan peringatan bila kecepatan relatif $> 0,7$ knot karena boom penahan mulai bocor [23].

3. Hasil dan Pembahasan

3.1 Perbandingan model pada set uji


Tabel 2. Hasil pada set uji Sentinel-1 (839 citra, agregasi global) dan uji lintas sensor PALSAR (776 citra).

Model	Thr	Dice/F1	IoU	Precision	Recall	PR-AUC	Dice PALSAR
Baseline dark-spot	–	0,7259	0,5698	0,6669	0,7964	–	0,6410
ML: Random Forest	0,40	0,8036	0,6717	0,7721	0,8377	0,8981	0,7506
ML: LightGBM	0,35	0,8056	0,6745	0,7568	0,8612	0,9020	0,7490
DL: U-Net Lite	0,45	0,8547	0,7462	0,8058	0,9099	0,9361	0,7774
DL: DeepLabV3+ MobileNetV2	0,50	0,8667	0,7648	0,8344	0,9016	0,9479	0,7975

Thr = threshold yang dipilih pada data validasi. Baseline mask kosong mencapai akurasi piksel 65,3% tanpa mendeteksi minyak sama sekali, sehingga akurasi tidak dipakai sebagai metrik utama. Tanpa 9 citra near-duplicate, Dice U-Net Lite hanya turun 0,0008.

Kedua model DL mengungguli model ML sekitar 5–6 poin Dice dan 7–9 poin IoU, dan semua model jauh di atas baseline (Tabel 2, Gambar 2). Selisih terbesar ada pada **precision**: fitur lokal model ML menandai hampir semua area gelap, termasuk tepi slick dan bercak *look-alike*, sedangkan DL memanfaatkan konteks spasial yang lebih luas. Model ML tetap 8 poin di atas baseline dengan ukuran yang sangat kecil. *Feature importance* menunjukkan fitur terpenting adalah minimum lokal 11 piksel, rata-rata lokal 11 piksel, dan selisih terhadap rata-rata citra, yaitu ukuran kegelapan relatif yang memang menjadi ciri slick pada SAR [1].

DeepLabV3+ pralatih unggul atas U-Net Lite pada Dice (+1,2 poin), precision (+2,9 poin), dan generalisasi lintas sensor (+2,0 poin), sedangkan U-Net Lite sedikit lebih tinggi recall-nya. Hal ini menunjukkan manfaat *transfer learning* meski citra SAR berbeda domain dengan ImageNet. Recall semua model DL $\approx 0,90$ – $0,91$; untuk peringatan dini HSSE sifat ini lebih aman karena tumpahan yang terlewat lebih mahal dampaknya daripada alarm palsu yang dapat diverifikasi analisis.



Gambar 2. Prediksi kelima model pada citra uji mudah, tipikal, sulit, dan tanpa minyak (merah = minyak).

3.2 Perbandingan dengan tolok ukur dataset SOS

Tabel 3. Perbandingan pada subset uji Sentinel-1 dataset SOS.

Model	mIoU (%)	F1 (%)	Recall (%)	Precision (%)	Ukuran model
U-Net [3]	81,46	86,10	81,22	85,61	tidak dilaporkan
DeepLabv3 [3]	82,94	87,70	84,76	88,08	tidak dilaporkan
CBD-Net [3]	83,42	87,87	87,32	91,20	tidak dilaporkan
LightGBM (ours)	73,43	80,56	86,12	75,68	0,24 MB
U-Net Lite (ours, INT8)	79,46	85,45	90,90	80,62	2,01 MB
DeepLabV3+ MobileNetV2 (ours, INT8)	81,23	86,73	90,16	83,44	4,84 MB

Nilai [3] dikutip dari Tabel III paper tersebut (threshold 0,5; cara agregasi tidak dirinci). mIoU kami = rata-rata IoU minyak dan IoU latar; recall/precision DeepLabV3+ dari model PyTorch, F1 dari varian INT8. Perbedaan protokol membuat perbandingan ini indikatif.

DeepLabV3+ mempersempit selisih F1 dengan CBD-Net [3] dari 2,4 poin (U-Net Lite) menjadi 1,1 poin, dengan model INT8 4,84 MB yang berjalan di browser. Recall model DL kami (90–91%) adalah yang tertinggi pada Tabel 3.

3.3 Efisiensi komputasi (Green/Edge AI)

Tabel 4. Ukuran, kesetaraan ONNX, dan latensi model yang dipakai di web.

Model (varian web)	Ukuran	Dice uji ONNX	Kesetaraan dengan notebook	Latensi CPU*	Latensi browser**
Dark-spot (ONNX)	<0,1 MB	0,7259	piksel identik 100%	0,3 ms	±1 ms
Random Forest (fitur + pohon)	1,83 MB	—	mask sama 99,98%†	218 ms	±270 ms
LightGBM (fitur + pohon)	0,24 MB	—	mask sama 99,98%†	349 ms	±410 ms
U-Net Lite INT8	2,01 MB	0,8545	FP32 7,77 MB: 0,8547	50 ms	105–122 ms
DeepLabV3+ INT8	4,84 MB	0,8673	FP32 17,5 MB: 0,8667	26 ms	±130 ms


onnxruntime CPU Colab (2 vCPU), 1 thread, batch 1, median 20 run. Chrome di laptop uji, onnxruntime-web WASM multi-thread (COOP/COEP), median 3 run setelah warm-up. †Diuji pada 100 citra uji acak karena inferensi pohon di CPU lambat

Kuantisasi INT8 memperkecil DeepLabV3+ 3,6 kali tanpa penurunan Dice, dan justru tercepat di CPU karena MobileNetV2 memakai konvolusi *depthwise*. Model ML berukuran paling kecil, tetapi paling lambat karena setiap piksel (65.536 per citra) harus melewati semua pohon. Semua model jauh di bawah target panduan (20–30 MB).

3.4 Analisis error

Dice per citra U-Net Lite memiliki median 0,797 (persentil-10 0,517; persentil-90 0,965). Kesalahan utama semua model adalah: (1) tumpahan sangat kecil dan garis gelap tipis yang tidak dilabeli (kemungkinan *look-alike* atau label terlewat); (2) batas slick, karena label berupa poligon kasar sedangkan prediksi lebih halus dan sedikit melebar; dan (3) pada model ML, bercak gelap kecil di area laut (Gambar 2). Performa per citra juga bervariasi: pada beberapa citra sulit, model ML dapat lebih baik daripada DL, sehingga aplikasi web menyediakan mode "bandingkan semua model" untuk analisis. Pada PALSAR, semua model turun 5–9 poin, sehingga *fine-tuning* diperlukan sebelum dipakai pada sensor atau wilayah lain.


4. Dampak Operasional, Efisiensi Biaya, dan Manajemen Risiko



Gambar 3. Aplikasi web: pilihan 5 model, area terdeteksi dengan poligon bernomor per slick, citra asli, dan peta probabilitas.

Solusi ini menysasar **Pilar HSSE** dan **efisiensi biaya**. Skenario penggunaannya adalah *screening* citra Sentinel-1 di sekitar anjungan, jalur pipa, dan terminal. Keluarannya (Gambar 3): poligon setiap slick dengan luas (km²) dan keliling, GeoJSON untuk GIS, dan simulasi respons (Gambar 4). Sebagai contoh, pada citra uji tipikal dengan resolusi 10 m/piksel, DeepLabV3+ mendeteksi 1,145 km² minyak. Dengan skenario angin 8 m/s dari timur laut, arus 0,3 m/s ke timur, dan ketebalan *rainbow* 5 μ m, slick bergerak 0,21 m/s ke tenggara, melebar $\pm 0,10$ km²/jam, dan saat tim tiba 3 jam kemudian

telah bergeser 2,3 km dengan luas $\pm 1,45 \text{ km}^2$. Kebutuhan *oil boom* untuk mengurung seluruh slick sekitar 16,4 km.



Gambar 4. Simulasi drift & penyebaran: posisi slick +6 jam (warna pelangi), jejak waktu (garis putus), dan oil boom saat tim tiba (pelampung oranye).

Efisiensi biaya. Kalkulator di web membandingkan patroli pencarian konvensional dengan CV + verifikasi analis. Dengan asumsi ilustratif (12 sortie/bulan $\times$ 4 jam $\times$ Rp45 juta/jam; 10 citra/bulan $\times$ 0,5 jam analis $\times$ Rp150 ribu/jam; 25% sortie tetap dibutuhkan untuk konfirmasi), biaya pemantauan turun dari Rp2,16 miliar menjadi Rp0,54 miliar per bulan (-75%). Citra Sentinel-1 tersedia gratis melalui Copernicus dan inferensi berjalan di browser sehingga biaya komputasinya praktis nol. Angka ini bergantung pada asumsi dan harus diganti dengan data kontrak perusahaan sebelum diklaim.

Tabel 5. Register risiko HSSE kegiatan pemantauan (L = kemungkinan, S = keparahan, skala 1–5).

Bahaya	S	Sebelum (L $\times$ S)	Sesudah CV (L $\times$ S)
Paparan uap hidrokarbon (VOC, H ₂ S) saat inspeksi jarak dekat	4	3 $\times$ 4 = 12	1 $\times$ 4 = 4
Kecelakaan penerbangan pengintaian	5	2 $\times$ 5 = 10	1 $\times$ 5 = 5
Insiden kapal patroli (jatuh ke laut, tabrakan)	4	3 $\times$ 4 = 12	1 $\times$ 4 = 4
Kebakaran/ledakan di dekat minyak segar	5	2 $\times$ 5 = 10	1 $\times$ 5 = 5
Kelelahan kru akibat patroli panjang & malam	3	4 $\times$ 3 = 12	2 $\times$ 3 = 6
Tumpahan terlambat diketahui (malam/berawan)	4	3 $\times$ 4 = 12	2 $\times$ 4 = 8
Risiko baru: salah deteksi / slick terlewat	3	—	3 $\times$ 3 = 9
Total skor risiko		68	41 (–40%)

Manajemen risiko. Pengurangan sortie pencarian menurunkan jam paparan personel di lapangan dari 192 menjadi 48 jam per bulan (-75%), sehingga kemungkinan (L) bahaya berbasis paparan turun dua tingkat, sedangkan keparahan (S) tetap karena konsekuensinya sama bila kejadian terjadi (Tabel 5). Pada hierarki pengendalian, pemindahan pencarian slick dari lapangan ke analisis citra termasuk **eliminasi paparan**. CV tidak menggantikan tim lapangan sepenuhnya: verifikasi, pengambilan sampel, dan pemasangan boom tetap dilakukan manusia, dan risiko baru berupa salah deteksi dikendalikan dengan verifikasi analis untuk setiap alarm.

Batasan. Dataset SOS tidak memiliki koordinat dan waktu akuisisi sehingga simulasi tidak dapat divalidasi terhadap kejadian nyata; simulasi juga tidak memodelkan penguapan, emulsifikasi, garis pantai, maupun angin/arus yang berubah. Simulasi diposisikan sebagai gambaran awal yang diperbarui dengan data cuaca/oseanografi dan citra berikutnya, seperti pada sistem operasional Petalas dkk. [10].

5. Kesimpulan dan Saran

Pada protokol yang sama, model DL mengungguli model ML untuk segmentasi tumpahan minyak Sentinel-1: DeepLabV3+ MobileNetV2 pralatih mencapai Dice 0,867 dan IoU 0,765 (1,1 poin F1 di bawah CBD-Net), U-Net Lite 0,855, sedangkan Random Forest dan LightGBM sekitar 0,805 dengan ukuran model jauh lebih kecil. Kelima model berjalan di browser, dan aplikasi web melengkapi deteksi dengan poligon per slick, simulasi arah dan laju penyebaran, estimasi kebutuhan oil boom, serta analisis biaya dan risiko HSSE.

Saran pengembangan: (1) menambah kelas *look-alike* dan data multi-sensor; (2) memproses citra Sentinel-1 penuh dengan *tiling* dan georeferensi sehingga poligon memiliki koordinat nyata; (3) menghubungkan simulasi dengan data angin dan arus operasional (misalnya Copernicus Marine) serta memvalidasinya dengan citra berurutan; (4) melakukan uji beberapa *seed* untuk mengukur variasi hasil; dan (5) validasi pilot di perairan Indonesia bersama tim HSSE untuk mengganti asumsi biaya dengan data nyata.

Daftar Pustaka

- [1] M. Fingas and C. Brown, "A review of oil spill remote sensing," *Sensors*, vol. 18, no. 1, p. 91, 2018, doi: 10.3390/s18010091.
- [2] R. Al-Ruzouq *et al.*, "Sensors, features, and machine learning for oil spill detection and monitoring: A review," *Remote Sensing*, vol. 12, no. 20, p. 3338, 2020, doi: 10.3390/rs12203338.
- [3] Q. Zhu *et al.*, "Oil spill contextual and boundary-supervised detection network based on marine SAR images," *IEEE Trans. Geosci. Remote Sens.*, vol. 60, pp. 1–10, 2022, doi: 10.1109/TGRS.2021.3115492.
- [4] M. Krestenitis *et al.*, "Oil spill identification from satellite images using deep neural networks," *Remote Sensing*, vol. 11, no. 15, p. 1762, 2019, doi: 10.3390/rs11151762.
- [5] M. Shaban *et al.*, "A deep-learning framework for the detection of oil spills from SAR data," *Sensors*, vol. 21, no. 7, p. 2351, 2021, doi: 10.3390/s21072351.
- [6] R. Hasimoto-Beltran, M. Canul-Ku, G. M. Díaz Méndez, F. J. Ocampo-Torres, and B. Esquivel-Trava, "Ocean oil spill detection from SAR images based on multi-channel deep learning semantic segmentation," *Marine Pollution Bulletin*, vol. 188, p. 114651, 2023, doi: 10.1016/j.marpolbul.2023.114651.
- [7] C. Li, D. Kim, S. Park, J. Kim, and J. Song, "A self-evolving deep learning algorithm for automatic oil spill detection in Sentinel-1 SAR images," *Remote Sensing of Environment*, vol. 299, p. 113872, 2023, doi: 10.1016/j.rse.2023.113872.
- [8] L. Liao, Q. Zhao, and W. Song, "Monitoring of oil spill risk in coastal areas based on polarimetric SAR satellite images and deep learning theory," *Sustainability*, vol. 15, no. 19, p. 14504, 2023, doi: 10.3390/su151914504.
- [9] K. Das, P. Janardhan, and M. R. Singh, "Oil spill detection in SAR images: A U-Net semantic segmentation framework with multiple backbones," in *Water and Environment, Volume 2*, Lecture Notes in Civil Engineering, vol. 414. Singapore: Springer, 2024, pp. 65–77, doi: 10.1007/978-981-97-7502-6_6.
- [10] S. Petalas, T. Psomouli, N. Kokkos, and G. Sylaios, "Operational oil-spill detection in the framework of digital twin using SAR imagery and deep learning," in *Proc. OCEANS 2025 Brest*, 2025, pp. 1–6, doi: 10.1109/OCEANS58557.2025.11104698.
- [11] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in *Proc. MICCAI 2015*, LNCS, vol. 9351. Cham: Springer, 2015, pp. 234–241, doi: 10.1007/978-3-319-24574-4_28.
- [12] B. Jacob *et al.*, "Quantization and training of neural networks for efficient integer-arithmetic-only inference," in *Proc. IEEE/CVF CVPR*, 2018, pp. 2704–2713, doi: 10.1109/CVPR.2018.00286.
- [13] BitsandLayers, "Deep-SAR SOS Oil Spill Detection Dataset," Kaggle, v1, 2026. [Online]. Available: <https://www.kaggle.com/datasets/bitsandlayers/sar-oil-spill-segmentation-dataset-sos> (diakses 24 Sep. 2026). Lisensi CC BY 4.0.
- [14] ONNX Runtime developers, "ONNX Runtime (onnxruntime-web) v1.30.0," 2026. [Online]. Available: <https://onnxruntime.ai>

- [15] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.
- [16] G. Ke *et al.*, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017, pp. 3146–3154.
- [17] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, and H. Adam, "Encoder-decoder with atrous separable convolution for semantic image segmentation," in *Proc. ECCV 2018*, LNCS, vol. 11211. Cham: Springer, 2018, pp. 833–851, doi: 10.1007/978-3-030-01234-2_49.
- [18] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted residuals and linear bottlenecks," in *Proc. IEEE/CVF CVPR*, 2018, pp. 4510–4520, doi: 10.1109/CVPR.2018.00474.
- [19] NOAA Office of Response and Restoration, "GNOME: General NOAA Operational Modeling Environment," 2024. [Online]. Available: <https://response.restoration.noaa.gov/gnome>
- [20] J. A. Fay, "Physical processes in the spread of oil on a water surface," in *Proc. Joint Conf. Prevention and Control of Oil Spills*, Washington, DC: API, 1971, pp. 463–467, doi: 10.7901/2169-3358-1971-1-463.
- [21] Bonn Agreement, "Bonn Agreement Aerial Operations Handbook: Bonn Agreement Oil Appearance Code," 2016. [Online]. Available: <https://www.bonnagreement.org>
- [22] A. Okubo, "Oceanic diffusion diagrams," *Deep Sea Research and Oceanographic Abstracts*, vol. 18, no. 8, pp. 789–802, 1971, doi: 10.1016/0011-7471(71)90046-5.
- [23] ITOPF, "Use of booms in oil pollution response," Technical Information Paper no. 3, London: ITOPF, 2011. [Online]. Available: <https://www.itopf.org>

Lampiran A. Contribution Statement

Tabel A1 merinci peran, tanggung jawab, dan persentase kontribusi tiap anggota (total 100%). Ketua mendapat porsi lebih besar karena merangkap koordinasi tim dan pemodelan inti.

Tabel A1. Pembagian peran dan kontribusi anggota Kelompok 1 CAYMAN.

Nama (NPM)	Peran	Tanggung jawab	Kontribusi
Ade Rizky Darmawan (23083010080), Ketua	Model Architect Specialist	Koordinasi tim; perancangan arsitektur U-Net Lite, training pipeline di GPU, pemilihan loss dan threshold, evaluasi metrik	20%
Arkananta Daniswara Handoyo (23083010059)	Data & Pipeline Specialist	Akuisisi dataset SOS, audit data (pasangan, label, duplikat), preprocessing, pembagian train/val/test	16%
Muhammad Arsyad Alzam (23083010082)	Deployment & Edge Specialist	Ekspor ONNX, kuantisasi FP16/INT8, benchmark latensi, onnxruntime-web, deployment Vercel, manajemen GitHub	16%
Choirul Amin (22083010050)	Frontend & UX Specialist	Desain dan pengembangan UI web, visualisasi hasil segmentasi, fitur Try Sample Data dan estimasi km ² , landing page tim	16%
Hana Titania Sastrian (23083010056)	Lead Technical Writer	Penyusunan laporan ilmiah, penelusuran dan pengelolaan referensi, dokumentasi README	16%
Zaydan Arief Athallah (23083010063)	Research & Business Impact Analyst	Kajian state of the art, analisis dampak operasional HSSE dan estimasi bisnis, materi presentasi	16%
Total			100%

Lampiran B. Artefak Proyek

- Repositori GitHub (publik): <https://github.com/aderizkydarmawan/cayman-oil-spill-sar>, berisi notebook Colab, skrip model/ekspor, hasil audit, metrik (JSON/CSV), model ONNX, dan kode web.
- Aplikasi web: <https://cayman-kelompok1.vercel.app>, yang memuat demo inferensi 5 model (*Try Sample Data*), poligon & GeoJSON per slick, simulasi penyebaran & oil boom, kalkulator biaya & risiko HSSE, dan profil tim.
- Reproduksi: buka notebooks/Kasus38_SAR_OilSpill_UNetLite.ipynb di Google Colab (runtime T4 GPU) lalu jalankan *Run all*; perbandingan ML vs DL ada di Bagian B (sel 14–19), hasilnya di outputs/v2/.